

Ciclo Contínuo de Melhoria do Dataset e Comparação de Modelos

Documento conceitual — visão geral da proposta, sem definição operacional dos detalhes de execução

1. Contexto

Atualmente, o processo de desenvolvimento dos modelos de detecção de folhas largas e folhas estreitas é conduzido por meio de testes isolados de modelos, sem um fluxo estruturado que conecte a qualidade dos dados aos resultados obtidos. Como consequência, os modelos treinados vêm apresentando desempenho limitado, na faixa de 60% de precision e recall, um patamar insuficiente para uso confiável em campo.

Este documento apresenta, em nível conceitual, a proposta de um ciclo contínuo de trabalho que conecta a evolução do dataset à evolução dos modelos, sem detalhar ainda a forma exata como cada etapa será operacionalizada.

2. O Problema Central: Qualidade do Dataset

O principal fator limitante identificado não é a arquitetura dos modelos testados, mas sim a qualidade e a confiabilidade das máscaras de segmentação que compõem o dataset de treinamento. Máscaras inconsistentes introduzem ruído sistemático no aprendizado, e nenhum ajuste de arquitetura ou hiperparâmetro é capaz de compensar isso de forma satisfatória.

Premissa central

Antes de investir esforço adicional em variações de modelo, é necessário investir na organização e na melhoria contínua da qualidade do dataset. O dataset é o gargalo atual, não o modelo.

Por esse motivo, a primeira prioridade não é encontrar a melhor arquitetura, e sim estabelecer um processo estruturado que eleve progressivamente a qualidade e a confiabilidade das máscaras existentes.

3. Proposta: Fluxo Contínuo de Interação com o Dataset

Propõe-se a criação de um fluxo contínuo — organizado em ciclos recorrentes — de interação entre a segmentação manual e o resultado dos modelos treinados. A ideia central é que o dataset deixe de ser um recurso estático, criado uma única vez, e passe a ser tratado como um artefato vivo, que é revisado, corrigido e ampliado periodicamente com base no que os próprios modelos revelam sobre suas fragilidades.

Cada ciclo deve, em linhas gerais:

- Trazer de volta ao processo de anotação os casos em que os modelos apresentam mais dificuldade ou incerteza;
- Permitir a correção e o refinamento de máscaras já existentes, e não apenas a criação de anotações novas;
- Alimentar o treinamento seguinte com uma versão incrementalmente mais confiável do dataset;
- Gerar evidências (métricas, comparações) que orientem o que precisa de atenção no ciclo seguinte.

Os detalhes operacionais de como esse fluxo será executado no dia a dia — ferramentas, prazos, volumes de imagem por rodada — serão definidos em etapa posterior. O objetivo deste documento é alinhar o conceito e a lógica do ciclo antes de entrar nesse nível de detalhamento.

4. Atividades de Pré-Iniciação do Ciclo

Antes de iniciar a execução dos ciclos propriamente ditos, é necessário organizar a base sobre a qual eles vão operar. Essa etapa preparatória inclui:

4.1 Organização dos modelos existentes

Levantamento e organização de todos os modelos já testados até o momento, consolidando o que já foi tentado, com quais dados e com quais resultados, evitando retrabalho e perda de conhecimento acumulado.

4.2 Organização das imagens do dataset

Estruturação do conjunto de imagens já coletadas, de forma que seja possível identificar origem, condições de coleta e status de anotação de cada imagem.

4.3 Criação de um versionamento

Estabelecimento de um sistema de versionamento tanto para os dados (imagens e máscaras) quanto para os modelos treinados, de modo que cada resultado obtido possa ser rastreado até a versão exata do dataset e do código que o gerou.

4.4 Código padrão de teste (local e Colab)

Definição de um código padronizado de teste e avaliação de modelos, que possa ser executado tanto em ambiente local quanto no Colab, garantindo que diferentes pessoas e diferentes execuções sejam comparáveis entre si.

5. Etapas do Ciclo

Em linhas gerais, cada ciclo deve conter um momento dedicado à melhoria do dataset e um momento dedicado à experimentação com modelos. Um ponto central desta proposta é que a etapa de experimentação não se limite a um único treinamento por ciclo:

Comparação paralela de modelos

A cada ciclo, mais de um modelo deve ser treinado em paralelo, variando arquitetura e/ou configurações de treinamento, de forma que os resultados possam ser comparados entre si a partir das mesmas métricas. Isso permite identificar, a cada rodada, não apenas se o dataset melhorou, mas também qual direção de modelo está respondendo melhor a essa melhoria.

Essa comparação paralela evita que o time fique preso a uma única linha de modelo por tempo demais, e cria, ao longo dos ciclos, um histórico comparável de qual combinação de dataset + arquitetura + configuração vem produzindo os melhores resultados.

A forma exata de seleção de imagens, os critérios de anotação, o número de modelos rodados em paralelo por ciclo e os critérios de comparação entre eles serão definidos em um momento posterior, de forma detalhada e operacional.

6. Automação e Centralização do Acompanhamento

É uma obrigação deste ciclo, e não apenas uma recomendação, que o processo seja o mais automatizado possível, reduzindo ao máximo a coordenação manual entre etapas. Todo o fluxo — desde a seleção de imagens até a promoção de um modelo — deve ser acompanhável a partir de uma única ferramenta central, onde qualquer pessoa do time consiga ver em que estágio cada imagem, lote ou modelo se encontra, sem depender de planilhas paralelas, mensagens avulsas ou controle manual.

Obrigação do ciclo

O ciclo deve ser conduzido de forma majoritariamente automatizada e centralizado em uma única ferramenta de acompanhamento (ex.: Trello, Jira, Notion ou equivalente), para a qual as imagens e lotes selecionados em cada rodada sejam enviados automaticamente, sem depender de envio manual entre pessoas.

Essa centralização cumpre dois papéis: elimina retrabalho de coordenação (quem já anotou o quê, o que já foi revisado, o que está pronto para treino) e cria um histórico visual do próprio ciclo, que passa a ser, por si só, uma fonte de rastreabilidade complementar ao versionamento técnico descrito na seção 4.

6.1 Exemplo ilustrativo de arquitetura automatizada

A seguir, um exemplo de como essa automação poderia ser estruturada. Trata-se de uma referência conceitual para orientar a discussão, não de uma definição fechada — a ferramenta específica, as colunas exatas e o grau de automação devem ser adaptados à realidade e à capacidade do time.

- Armazenamento central das imagens e máscaras (ex.: bucket em nuvem ou Google Drive), organizado conforme o versionamento definido na etapa de pré-iniciação;
- Script de seleção automática, que identifica periodicamente as imagens prioritárias do ciclo (ex.: casos de baixa confiança do modelo atual) e as separa em um lote;
- Criação automática de cartões na ferramenta de acompanhamento para cada imagem ou lote selecionado, via API/integração, eliminando o envio manual;
- Colunas do quadro representando o estágio de cada item no ciclo, por exemplo: Selecionadas → Em anotação → Em revisão (QA) → Prontas para treino → Em treinamento → Avaliadas → Aprovadas;
- Disparo automático do treinamento assim que um lote atinge a coluna "Prontas para treino", sem exigir acionamento manual;
- Notificações automáticas (ex.: Slack, e-mail) quando um cartão muda de estágio ou quando um novo modelo está pronto para avaliação.

Flexibilidade de adaptação

Este é apenas um exemplo ilustrativo de arquitetura. O time tem liberdade para adaptar a ferramenta, os nomes das etapas, o nível de automação e as integrações específicas, desde que o princípio seja mantido: o mínimo possível de coordenação manual e um único ponto central de acompanhamento do ciclo.

6.2 Exemplo de técnica automatizável: detecção de erros de anotação por validação cruzada

Uma técnica que se encaixa bem nesse modelo de automação é o uso de validação cruzada para localizar, de forma automática, imagens com anotações provavelmente incorretas — reduzindo a necessidade de revisar o dataset inteiro às cegas. A lógica geral é:

- Dividir o dataset em partições (por exemplo, duas metades, ou idealmente mais partições — k-fold — quando o volume de dados permitir);
- Treinar um modelo equivalente em cada partição;
- Testar cada modelo nas imagens que ele não viu no treino (a partição usada para treinar o outro modelo);
- Medir a discordância entre a máscara prevista pelo modelo e a máscara anotada (ex.: IoU/Dice por instância);
- Priorizar para revisão manual as imagens com maior discordância, encaminhando-as automaticamente para a fila de revisão na ferramenta de acompanhamento.

Complementar, não substitui a revisão manual

Essa técnica é eficaz para localizar erros inconsistentes de anotação (ex.: uma imagem específica anotada de forma diferente do padrão), mas não captura erros sistemáticos que se repetem igualmente em todas as partições, como um critério mal definido no guia de anotação. Por isso, deve ser tratada como complementar ao double-pass e à revisão de qualidade já previstos no processo de anotação, e não como substituto deles.

Por depender apenas de dados e modelos já existentes no fluxo, essa verificação pode ser executada de forma automática e periódica, alimentando diretamente a fila de revisão da ferramenta central de acompanhamento com os candidatos mais prováveis a erro.

7. Papéis no Ciclo

Para que o ciclo funcione de forma consistente, é necessário que cada frente de trabalho tenha um responsável claro. A tabela abaixo apresenta os papéis identificados como necessários; a definição de quem assume cada um será feita em conjunto com o time.

Papel	Responsabilidade principal	Responsável
Curadoria e seleção do dataset	Decide quais imagens/casos entram em cada rodada de melhoria do dataset.	
Anotação e correção de máscaras	Realiza e revisa a segmentação manual, garantindo qualidade e consistência.	
Experimentação e treinamento	Conduz os treinamentos comparativos entre arquiteturas e configurações.	
Avaliação e decisão de promoção	Analisa métricas, compara modelos e decide o que avança para produção.	
Infraestrutura e versionamento	Mantém a organização de dados, modelos, código e ambientes de teste.	

Uma mesma pessoa pode acumular mais de um papel, especialmente nos primeiros ciclos, mas é importante que cada responsabilidade tenha um dono explícito, evitando que etapas críticas — sobretudo a revisão de qualidade das anotações — sejam informalmente esquecidas.

8. Próximos Passos

- Validar este documento conceitual com o time envolvido;
- Executar as atividades de pré-iniciação (organização de modelos, imagens, versionamento e código padrão de teste);
- Escolher a ferramenta central de acompanhamento do ciclo e desenhar as integrações automáticas necessárias;
- Definir, em documento operacional separado, os detalhes de execução de cada etapa do ciclo;
- Atribuir os papéis definidos na seção 7.